

Normalisation Dans le contexte des BDR, la normalisation est le processus visant à optimiser la modélisation du MR faite par le concepteur. Le processus de modélisation proposé passant par le modèle EA et ensuite par le MR pourrait produire certaines anomalies indésirables. En suivant rigoureusement le processus de normalisation, l'optimisation obtenue tendra vers une solution quasi optimale d'un point de vue théorique.

- 3
- L'objectif de cette manipulation consiste à modifier le modèle relationnel initialement créé par le concepteur afin :
 - d'éliminer toutes les redondances;
 - ▶ de découper adéquatement les structures dépendantes.
- Ainsi, la robustesse de la nouvelle solution permettra :
 - ▶ une meilleure compréhension des interrelations entre chacune des données;
 - de minimiser la tâche de modification de la structure lorsqu'on désirera la mettre à jour avec de nouveaux éléments;
 - d'éviter la redondance (intégrité ainsi que contre-performance liée);
 - d'éviter les anomalies transactionnelles : insertion, suppression et de mise à jour;
 - ▶ de faciliter l'écriture des requêtes non prévues au moment de la conception.

Normalisation

- ▶ Le processus de normalisation consiste principalement à diviser les relations initiales en plus petites relations tout en définissant les liens qui les unissent.
- Ainsi, les opérations d'insertion, de suppression et de consultation se feront d'abord dans la table concernée et ensuite se propageront dans les tables liées s'il y a lieu.
- ▶ Finalement, on dira qu'une BDR est normalisée si elle respecte les formes normales.

Normalisation Formes normales

5

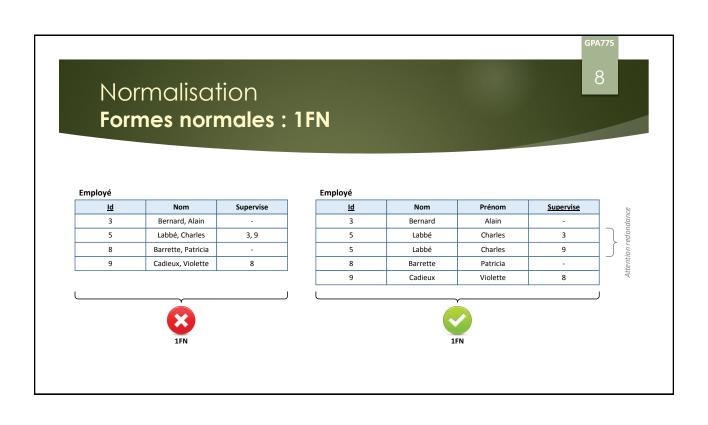
- ► Formellement, il existe neuf formes normales :
 - 1. la 1er forme normale : « 1NF »:
 - 2. la 2e forme normale : « 2NF »;
 - 3. la 3e forme normale : « 3NF »;
 - 4. la forme normale de clé élémentaire : « EKNF »;
 - 5. la forme normale de Boyce Codd: « BCNF »;
 - 6. la 4e forme normale : « 4NF »;
 - 7. la 5e forme normale : « 5NF »;
 - 8. la forme normale domaine clef: « DKNF »;
 - 9. la 6e forme normale : « 6NF ».

Normalisation Formes normales

- Les formes normales 1 et 2 sont essentielles à un MR formel.
- Très souvent, le processus de normalisation respecte uniquement les trois premières formes normales.
- ▶ Dans le cadre du cours, on mettra l'emphase sur les 4 premières;
- ▶ Pourquoi les quatre dernières formes sont moins utilisées :
 - elles sont plus abstraites et souvent difficiles à identifier;
 - lorsqu'elles sont appliquées, elles apportent un découpage sévère du MR pour les parties concernées;
 - > souvent, les règles identifiées sont abrogées lors du processus de dénormalisation.

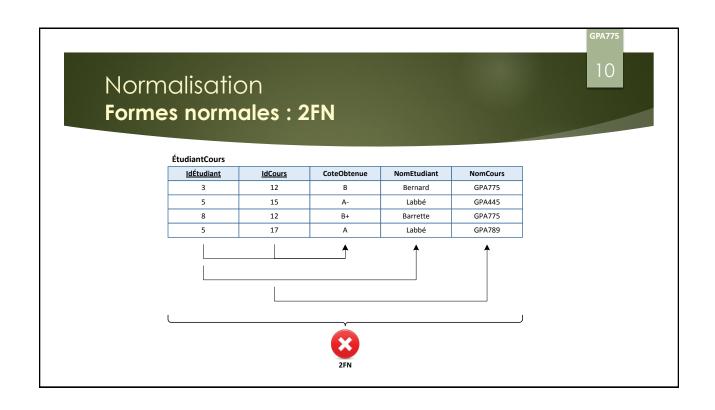
Normalisation Formes normales: 1FN

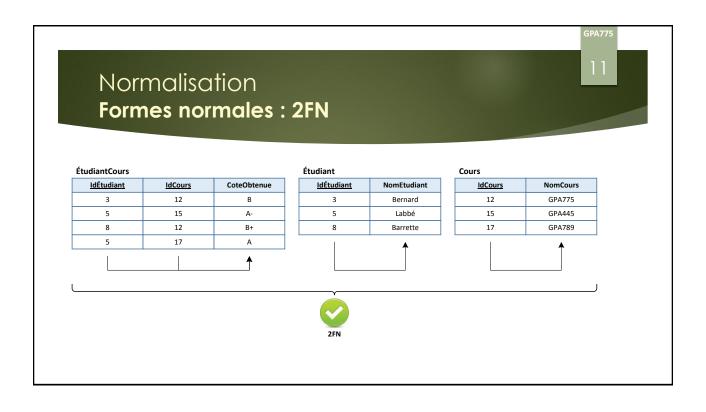
- ▶ Une relation respecte la 1ère forme normale si et seulement si :
 - ▶ tous les attributs sont atomiques (valeur scalaire, indivisible).
- ▶ Impacts:
 - les attributs composites sont interdits;
 - les attributs multivalués sont interdits;
 - impose implicitement qu'un attribut membre de la clé primaire soit à valeur unique;
 - permet d'augmenter grandement la performance du SGBD en évitant de parcourir des attributs sous forme de liste et en créant des indexes performants.

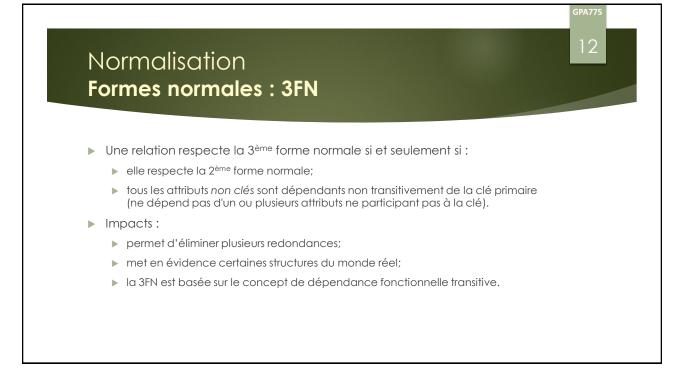


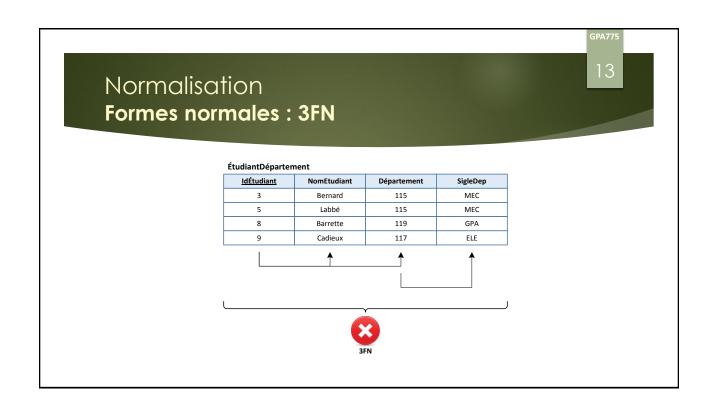
Normalisation Formes normales: 2FN

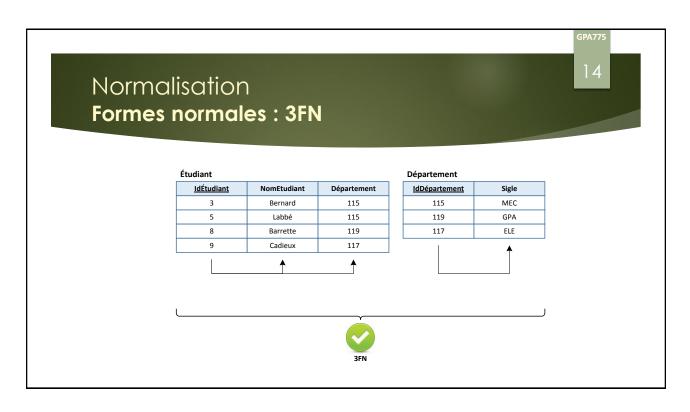
- ▶ Une relation respecte la 2ème forme normale si et seulement si :
 - ▶ elle respecte la 1ère forme normale;
 - ▶ tous les attributs non clés sont complètement dépendants de la clé primaire (ne peuvent dépendre que d'une partie de la clé primaire).
- ▶ Impacts:
 - permet d'éliminer plusieurs redondances;
 - met en évidence certaines structures du monde réel;
 - ▶ la 2FN est basée sur le concept de dépendance fonctionnelle complète.





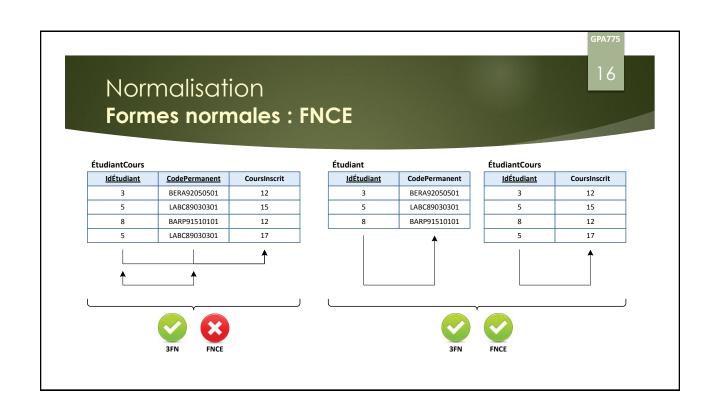






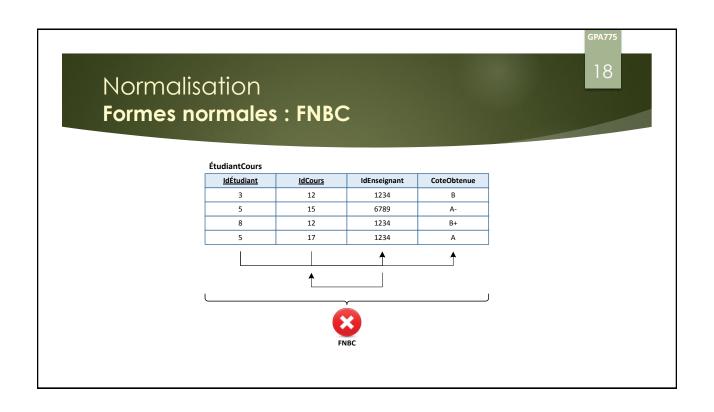
Normalisation Formes normales: FNCE

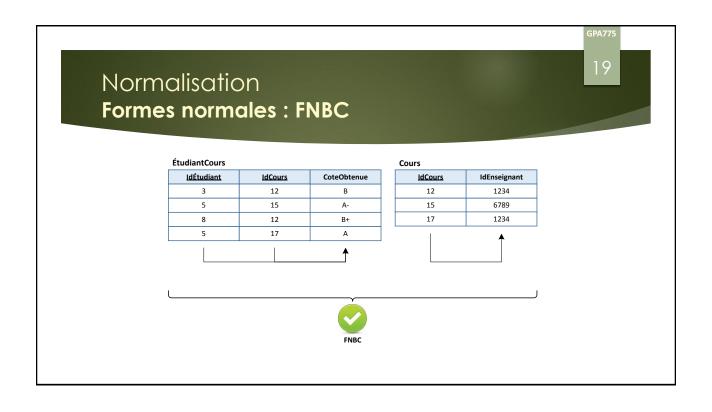
- Une relation respecte la forme normale de clé élémentaire si et seulement si:
 - elle respecte la 2^{ème} forme normale;
 - ▶ tous les éléments de dépendance fonctionnelle débutent avec la clé complète ou terminent sur un attributs *non cl*és (n'arrive que lorsqu'une clé primaire est composée de plusieurs attributs et que certains d'entre eux se chevauchent).
- Impacts:
 - permet d'éliminer certaines redondances plus rares;
 - met en évidence certaines structures plus subtiles du monde réel;
 - on remarque que la FNCE est une amélioration de la 3FN (la 3FN n'est pas nécessairement une FNCE alors qu'une FNCE est une 3FN).

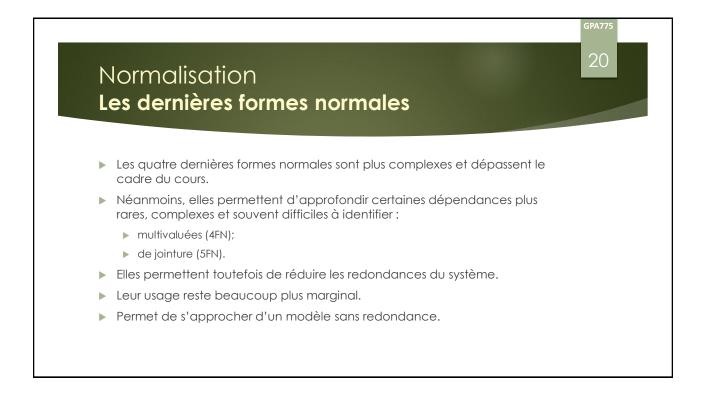


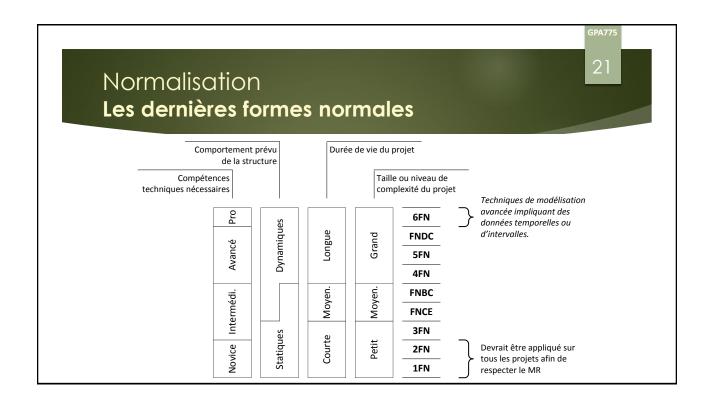
Normalisation
Formes normales: FNBC

- ▶ Une relation respecte la forme normale de Boyce-Codd si et seulement si:
 - ▶ elle respecte la 3^{ème} forme normale;
 - tous les attributs non-clé ne sont pas source de dépendance vers une partie de la clé ().
- ▶ Impacts:
 - permet d'éliminer certaines redondances plus rares;
 - met en évidence certaines structures plus subtiles du monde réel.









Normalisation Dépendances fonctionnelle (DP) est une contrainte entre deux attributs (ou groupes d'attributs) de la même relation. Plus précisément, l'étude des DF consiste à identifier les attributs dominants d'une relation. (ci, le terme dominant fait référence à la notion de détermination; c'est-à-dire, les attributs d'une relation qui permettent de retrouver d'autres attributs. Bref, les DF représentent la généralisation du concept de clé. Son analyse détaillée permet la réalisation du processus de normalisation. Elle permet d'identifier les lieux de fractionnement des relations qui ne respectent pas les critères de normalisation. Le théorème de Heath propose une stratégie simple et efficace permettant de s'approcher naturellement d'une 3FN.

Normalisation **Dépendances fonctionnelles**

23

- Éléments syntaxiques :
 - ▶ soit **R** une relation et **X**, **Y**, **Z** des attributs de **R**
 - \triangleright soit r un tuple donné de R et x, y, z les valeurs des attributs X, Y, Z du tuple r
 - ▶ une dépendance fonctionnelle est notée par : X → R Y
 - ▶ l'énoncé précédent se dit : l'attribut X détermine l'attribut Y de la relation R
 - \blacktriangleright en d'autres mots, $\textbf{X} \rightarrow^{\mathbb{R}} \textbf{Y}$ signifie qu'en connaissant la valeur de x , on peut connaître celle de y
- on simplifie souvent l'écriture en omettant les virgules et le nom de la relation, par exemple :
 - ▶ $X, Y \rightarrow R Z$ devient $XY \rightarrow Z$

Normalisation Dépendances fonctionnelles

24

Par exemple, voici l'étude partielle des DF de la relation ZIP :

A →Zip A

trivial

A →Zip C

validé

C →Zip A

faux

▶ A, B →Zip D

incertain

A, C →Zip D

faux

▶ ...

Attention aux conclusions faciles! Il vaut mieux faire une analyse logique de la structure plutôt qu'une simple analyse du contenu de R. Zip

•			
Α	В	С	D
a1	b1	c1	d1
a1	b2	c1	d2
a2	b2	c2	d2
a2	b3	c2	d3
a3	b3	c2	d4
	A a1 a1 a2 a2	A B a1 b1 a1 b2 a2 b2 a2 b3	A B C a1 b1 c1 a1 b2 c1 a2 b2 c2 a2 b3 c2

Normalisation **Dépendances fonctionnelles**

25

▶ Par exemple, voici un cas ambigu sans analyse contextuelle :

ightharpoonup Id ightharpoonupÉtudiantCours Nom, SigleCours validé

▶ SigleCours → ÉtudiantCours Nom faux

Malgré l'exemple donné, la 2ème affirmation est erronée. Cette supposition implique que chaque cours n'a qu'un seul étudiant.

ÉtudiantCours

<u>Id</u>	Nom	SigleCours	
3	Bernard	GPA445	
5	Labbé	GPA665	
8	Barrette	GPA775	
9	Cadieux	GPA789	

Normalisation

Propriétés des dépendances fonctionnelles

26

- Propriétés de base :
 - Réflexivité

si **Y** est inclus dans **X** ($Y \subseteq X$) ou si **Y** est un sous élément de **X**, alors **X** \rightarrow **Y** un exemple évident, si **VW** \rightarrow **Z**, alors **VW** \rightarrow **WZ**, **VW** \rightarrow **VZ** et **VW** \rightarrow **VWZ** ce type de DF est identifié comme étant une DF triviale

Augmentation si X → Y, alors WX → WY

► Transitivité si $X \rightarrow Y$ et que $Y \rightarrow Z$, alors $X \rightarrow Z$ Normalisation Propriétés des dépendances fonctionnelles

- Propriétés dérivées :
 - Pseudo-transitivité

si $X \rightarrow Y$ et que $WY \rightarrow Z$, alors $XW \rightarrow Z$

démonstration : 1. $X \rightarrow Y$ devient $XW \rightarrow YW$

2. sachant que $XW \rightarrow YW$ et $YW \rightarrow Z$ on obtient XW → Z

par augmentation

par transitivité

Union

si $X \rightarrow Y$ et que $X \rightarrow Z$, alors $X \rightarrow YZ$

démonstration : 1. $X \rightarrow Y$ devient $XZ \rightarrow YZ$

2. sachant que $X \rightarrow Z$ et $XZ \rightarrow YZ$ on obtient $X \rightarrow YZ$

par augmentation

par pseudo-transitivité

Normalisation Propriétés des dépendances fonctionnelles

Propriétés dérivées :

Décomposition

si $X \rightarrow YZ$, alors $X \rightarrow Y$ et $X \rightarrow Z$

démonstration : 1. on obtient $YZ \rightarrow Y$ et $YZ \rightarrow Z$

2. sachant que $X \rightarrow YZ$, $YZ \rightarrow Y$ et $YZ \rightarrow Z$

on obtient $X \rightarrow Y$ et $X \rightarrow Z$ par transitivité

Composition

si $X \rightarrow Y$ et que $V \rightarrow W$, alors $VX \rightarrow WY$

démonstration : 1. $X \rightarrow Y$ devient $VX \rightarrow VY$

 VX → VY devient VX → Y
 sachant que V → W et VX → Y on obtient VX → WY

par augmentation par réflexivité

par union

Fermeture des dépendances fonctionnelles

- La fermeture, noté **F***, est l'ensemble de toutes les dépendances fonctionnelles pouvant être produite pour une relation.
- ▶ Pour déterminer **F**⁺, il faut utiliser les propriétés des DF afin identifier toutes les DF indirectes qui existent à partir de l'ensemble les DF connues, noté **F**.
- ▶ Un exemple, supposons la relation R données ainsi que l'ensemble des éléments F déterminées par le concepteur :

R (A, B, C, D, E)

F:

 $A \rightarrow BC$ $CD \rightarrow E$

 $B \rightarrow D$

 $E \rightarrow A$

Normalisation Fermeture des dépendances fonctionnelles

30

- Connaissant la liste des dépendances fonctionnelles, on tente de trouver **F**⁺, l'ensemble des DF logiquement impliquées par celles données.
- A → B et A → C par décomposition : A → BC
- A → D
 par transitivité : A → B et que B → D
- A → CD par union : A → C et que A → D
- A → E
 par transitivité : A → CD et que CD → E

 $\begin{array}{c} R \; (A,\,B,\,C,\,D,\,E) \\ \digamma \\ A \to BC \\ CD \to E \\ B \to D \\ E \to A \\ \\ \digamma^+ \\ A \to B \\ A \to C \\ A \to D \\ A \to CD \\ A \to E \\ \end{array}$

Fermeture des dépendances fonctionnelles

5. A → ABCDE

par union : $A \rightarrow A$ (trivial), $A \rightarrow B$, $A \rightarrow C$, $A \rightarrow D$ et $A \rightarrow E$

6. E → ABCDE

par transitivité : **E** → **A** et que **A** → **ABCDE**

7. CD → ABCDE

par transitivité : CD → E et que E → ABCDE

8. $BC \rightarrow CD$

par augmentation : $\mathbf{B} \to \mathbf{D}$

9. BC → ABCDE

par transitivité : BC → CD et que CD → ABCDE

► Cet exemple donne finalement 4 clés candidates : A, E, CD et BC

 $\begin{array}{c} R \; (A,\,B,\,C,\,D,\,E) \\ \hline F \\ & A \to BC \\ & CD \to E \\ & B \to D \\ & E \to A \\ \hline \\ F^+ \\ & A \to B \\ & A \to C \\ & A \to D \\ & A \to CD \\ & A \to E \\ & A \to ABCDE \\ & E \to ABCDE \\ & CD \to ABCDE \\ & BC \to CD \\ & BC \to ABCDE \\ \hline \end{array}$

32

Normalisation

Dépendances fonctionnelles : Théorème de Heath

- Le théorème de Heath stipule qu'il est possible de minimiser les redondances d'une relation en la divisant en plusieurs sous relations. Cette division doit cependant se faire sous cette condition: la décomposition doit se faire sans perte (dans le jargon, on parle de jonction conservatrice, c'est-à-dire qu'il soit possible de retrouver la relation initiale à partir des relations créées). La règle suivante permet d'assurer cette condition.
- ▶ Soit **R** une relation, **F** un ensemble de DF, \mathbf{R}_1 et \mathbf{R}_2 une décomposition de **R**. Alors, cette décomposition est sans perte si au moins l'une des dépendances fonctionnelles suivantes est dans \mathbf{F}^* :
 - $ightharpoonup R_1 \cap R_2 \rightarrow R_1$
 - $Arr R_1 \cap R_2 \rightarrow R_2$

Dépendances fonctionnelles : Théorème de Heath

- Un exemple : soit la relation Emprunt (Agence, AvoirAg, VilleAg, IdPrêt, Client, Montant)
- ▶ Ainsi que l'ensemble **F** imposé par le concepteur :

Agence → **AvoirAg**: une agence ne possède qu'un seul avoir

Agence → VilleAg: une agence se situe dans une seule ville

IdPrêt → Montant: un seul prêt par numéro de prêt

IdPrêt → Agence: un numéro de prêt ne se trouve que dans une seule agence

- ▶ Pour cet exemple, supposons : $F^+ = F$
- On désire décomposer la relation Emprunt de sorte qu'elle soit à jonction conservatrice.

Normalisation

_

Dépendances fonctionnelles : Théorème de Heath

- Étape 1 : décomposition d'Emprunt en 2 sous relations
 R₁ (Agence, AvoirAg)
 R₁' (Agence, VilleAg, IdPrêt, Client, Montant)
- ▶ Est-ce que R₁ est à jonction conservatrice?
 - ▶ d'abord, $R_1 \cap R_1' = \{ Agence \}$
 - est-ce que { Agence } → R₁ ou { Agence } → R₁' on sait de F* que Agence → AvoirAg donc, par augmentation on obtient : Agence → Agence, AvoirAg finalement, R₁ ∩ R₁' → R₁
- ▶ R₁ est à jonction conservatrice.

33

.

Dépendances fonctionnelles : Théorème de Heath

- \blacktriangleright Étape 2 : décomposition de la relation restante R_1 ' en 2 sous relations R₂ (Agence, VilleAg) R2' (Agence, IdPrêt, Client, Montant)
- ► Est-ce que R₂ est à jonction conservatrice?
 - ▶ d'abord, $R_2 \cap R_2' = \{ Agence \}$
 - ▶ est-ce que { Agence } \rightarrow R₂ ou { Agence } \rightarrow R₂' on sait de F⁺ que Agence → VilleAg donc, par augmentation on obtient: Agence → Agence, VilleAg finalement, $R_2 \cap R_2' \rightarrow R_2$
- R₂ est à jonction conservatrice.

Normalisation

Dépendances fonctionnelles : Théorème de Heath

- \triangleright Étape 3 : décomposition de la relation restante R_2 ' en 2 sous relations R₃ (IdPrêt, Montant) R₃' (Agence, IdPrêt, Client)
- Est-ce que R₃ est à jonction conservatrice?
 - ▶ d'abord, $R_3 \cap R_3' = \{ IdPrêt \}$
 - est-ce que { IdPrêt } → R₃ ou { IdPrêt } → R₃' on sait de F⁺ que IdPrêt → Montant donc, par augmentation on obtient: IdPrêt → IdPrêt, Montant finalement, $R_3 \cap R_3' \rightarrow R_3$
- ▶ R₃ est à jonction conservatrice.

35

37

Dépendances fonctionnelles : Théorème de Heath

- Étape 4 : décomposition de la relation restante R₃' en 2 sous relations R₄ (IdPrêt, Agence) R₄' (IdPrêt, Client)
- ▶ Est-ce que R₄ est à jonction conservatrice?
 - ▶ d'abord, $R_4 \cap R_4' = \{ IdPrêt \}$
 - est-ce que { IdPrêt } → R₄ ou { IdPrêt } → R₄' on sait de F* que IdPrêt → Agence donc, par augmentation on obtient : IdPrêt → IdPrêt, Agence finalement, R₄ ∩ R₄' → R₄
- ▶ **R**₄ est à jonction conservatrice.

GPA775

38

Normalisation

Dépendances fonctionnelles : Théorème de Heath

- Étape 5 : aucune décomposition n'est possible, on obtient alors le schéma relationnel suivant :
 - R₁ (Agence, AvoirAg)
 - R₂ (Agence, VilleAg)
 - R₃ (IdPrêt, Montant)
 - R₄ (IdPrêt, Agence)
 - R_5 (IdPrêt, Client) ($R_5 = R_4$ ')
- ▶ Cette décomposition est optimale et sans perte, néanmoins...

Normalisation **Avantages**

39

- redondance réduite:
- ▶ intégrité plus facile à assurer : la BD reste dans un état consistant;
- réduit les anomalies transactionnelles présentées;
- moins de données => taille réduite des tuples
 - ▶ plus petite BD (plus performante et moins coûteuse);
 - ▶ plus de tuples peuvent être traités en E/S;
 - ▶ plus de tuples peuvent être mis en mémoire vive et mémoire cache;
 - affichage facilité;
- clarifie la structure et les liens du monde réel.

Normalisation Inconvénients

- ▶ le grand nombre de relation générée apporte un grand nombre de jonction potentiel;
- or les jonctions peuvent être très coûteuses en performance (traitement et E/S;
- malgré les efforts réalisés, une normalisation stricte réduit généralement la performance du système.

Normalisation **Dénormalisation**

41

- La dénormalisation est un processus intentionnel visant à s'éloigner de la normalisation afin d'améliorer les performances globales du SGBD en réduisant la charge de traitement causée par des jointures inappropriées.
- ▶ Elle consiste à établir les compromis nécessaires de la normalisation qui tient compte des structures les plus sollicitées (traitement et E/S).
- ▶ Elle doit donc s'effectuer après la normalisation.
- L'analyse des besoins permet d'identifier les éléments névralgiques et de les amalgamer ensemble. Évidemment, ce processus provoque systématiquement :
 - ▶ la perte du respect des formes normales;
 - ▶ la redondance des données.
- ▶ Peut être appliquée sur des attributs et des relations entières.

Normalisation Dénormalisation

GPA775

- ▶ La dénormalisation est une tâche souvent négligée à cause de l'ampleur du travail qu'elle demande.
- ▶ Trop souvent, le processus est bâclé et les concepteurs se contentent d'une analyse sommaire et intuitive.
- ▶ D'un point de vue formelle, cette tâche est plus complexe qu'il n'y paraît et dépasse largement le cadre du cours.
- ▶ Elle requiert une analyse détaillée des requis initiaux afin d'établir la fréquence des besoins liés au traitement des données. Souvent, des études opérationnelles sont réalisées par la mise en œuvre d'un plan d'optimisation basé sur des simulations (souvent difficiles et coûteux à mettre en œuvre). Néanmoins, ces approches détaillées permettent d'établir les compromis optimaux du système.
- ▶ En général, ce sont les DBA chevronnés qui s'attaquent à cette problématique.

Normalisation Dénormalisation

43

- Malgré tout, les avantages de la dénormalisation sont importants :
 - ▶ minimise le besoin de jonctions;
 - réduit le nombre de clés étrangères;
 - réduit le nombre d'index;
 - réduit le nombre de relations.
- ▶ Le choix d'un bon schéma sera toujours un compromis entre la performance de la BD (moins de jonction) et l'absence d'anomalies de mise à jour (pas de redondance de données).

Normalisation **Processus**

- 1. Modélisation du projet avec le schéma EA
- 2. Transformation du modèle EA vers le MR
- 3. Identification de **F** et de **F**⁺ pour chaque relation. Attention aux clés étrangères qui ne doivent pas être traitées comme les autres attributs. Ils doivent resté lié à la clé primaire.
- 4. Pour chaque relation, s'assurer du respect des formes normales sélectionnées pour le projet (1FN, 2FN, 3FN, ...).
 Attention, les 2 premières formes normales devraient toujours être respectées.
- 5. Dénormalisation
- 6. Documentation!